一个基于大模型的数学与算法的交互式维基论坛

MathWiki Lab • 项目技术文档

面向数学与算法学习的可阅读、可追问、可回查知识工作区。

项目组长：陈子扬

项目成员：郑竣杰

指导教师：陈伟（副教授）

文档日期：2026 年 10 月 25 日

版本口径：当前代码实现与既有生产截图记录。新增改进须部署后验收；不把申报阶段设想写成已完成成果。

代码仓库：https://github.com/moonriver05/-

关键词：数学教育 / 检索增强生成 / 原文证据 / 分层解释 / 低内存部署

01 项目概述与阅读导航

1.1 问题与定位

数学与算法词条往往定义严谨、前置知识多。初学者即使搜索到文章，也难以判断从何理解；独立聊天工具又容易脱离词条语境，使“看文章、问问题、核对答案”分散在不同界面。

MathWiki Lab 将知识阅读、AI 分层解释、连续追问和针对原句的讨论合并到一个工作区。项目目标是降低理解门槛并让回答有可检查的来源，而不是替代教材、教师或形式化证明系统。

1.2 当前成果

公开内容库包含 5,000 篇中文词条和 48,845 个可见章节。生产向量库已完成 48,560 个有效正文片段的建库。两种数量统计对象不同，不能相互当作覆盖率分母。

已实现标题搜索、结构化正文、四档程度与四种解释方式、SSE 流式生成、对话追问、公开原文回查、批注评论、账户与审核、H5 工作区。语音和 Elasticsearch 保留可选适配，当前生产演示未启用。

1.3 章节导航

02 需求分析；03 系统架构；04 数据与结构；05 AI 选型；06 建库；07 在线检索；08 生成与校验；09 分层教学；10 核心交互；11 安全与费用；12 测试；13 部署；14 创新；15 总结展望；16 团队与参考。

02 需求分析

2.1 角色与场景

角色	主要诉求	验收方式
访客	找到条目并读懂结构	可检索、阅读、查看公开讨论
学习者	按程度解释、追问、核对	有分层回答、引用和原文跳转
社区参与者	针对具体原句交流	选句批注、回复、处理结果
管理员	控制内容与账户质量	审核、回收站、反馈和操作记录

2.2 功能需求

• 阅读：显示章节、公式、表格、图片与来源；复杂模板明确提示，不假装完整解析。

• 检索：标题搜索与阅读分离操作，不因输入搜索词就清空当前对话。

• AI：当前文章语境、多轮追问、可中止的流式展示、原文证据与失败提示。

• 个性化：按小学生、高中生、本科生、专业学习者调整语言，并支持生活类比、直觉与严谨、公式推导、例题演示。

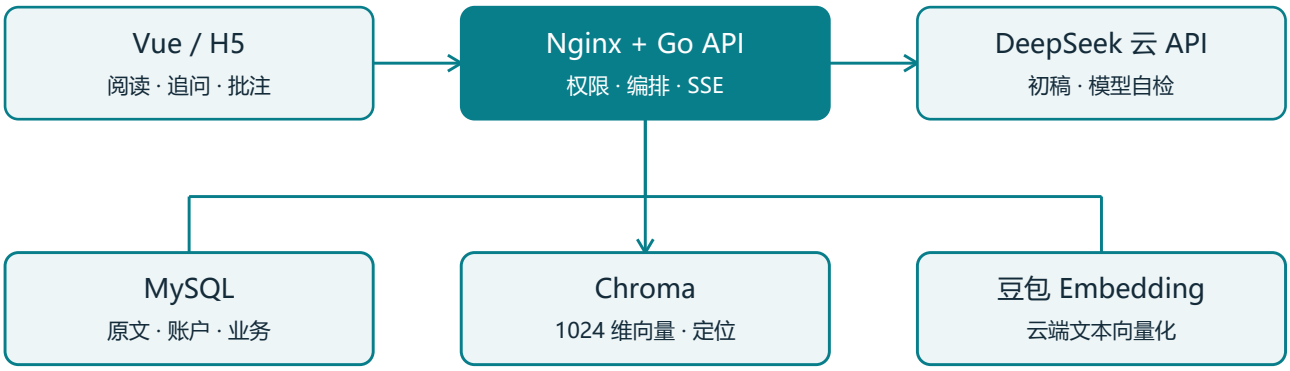
• 社区：账户隔离、收藏、批注、回复、反馈、审核与恢复。

2.3 非功能需求与限制

有限资源：生产主机约 2 核、1.8 GiB 内存，避免额外部署本地大模型。可解释性：用户能看到引文与出处。可恢复性：建库幂等、卷持久化、失败回退。可维护性：前后端类型检查、模块边界和自动化测试。

尚未形成大样本教学效果或多人并发评价，因此不报告虚构的准确率、满意度和吞吐量。

03 系统架构设计



3.1 模块职责

Vue 负责搜索、阅读、对话、审核等交互；Nginx 统一静态资源与同源 API。Go API 承担账户权限、内容审核、原文查询、RAG 编排和流式输出。GORM 对接正式 MySQL，SQLite 只用于开发和自动测试。

Chroma 保存向量及少量定位元数据，MySQL 保留权威原文与业务状态。embedding 与语言生成通过不同云端接口完成，密钥均在服务端。

3.2 依赖隔离

mail、storage、search、speech 为独立适配器。未配置模型时返回明确标记的演示解释；RAG 不可用时基于当前词条回退；ES 默认不启用。当前架构没有 LangChain 或自训练模型，不应将团队过去的经验写成本项目依赖。

04 数据设计与代码结构

4.1 主要实体

实体	关键职责
Article / Section	标题、分类、来源、许可、章节位置和公开状态
User / Session	身份、角色、禁用状态与会话摘要
Annotation / Comment	原句批注、回复和审核状态
Favorite / ReadingHistory	个人收藏与阅读记录
ExplanationRecord / Feedback	AI 答案记录和反馈
AdminAudit	管理操作审计

公开内容导出采用字段白名单，不因数据库模型增加字段而悄悄发布账户信息。分片清单记录数量与 SHA-256，导入前校验，已有内容时拒绝覆盖。

4.2 代码组织

backend/cmd 编排启动、导入与索引工具；internal/api 管理业务与权限；internal/ai 负责模型协议与教学约束；internal/rag 负责向量、分块、原文校验；internal/model 定义数据模型。前端按 API、工作区组件、流式解析、媒体清洗及测试拆分。

Go 使用 gofmt 和 go vet，前端使用 TypeScript / vue-tsc 与锁定依赖。关键注释说明信任边界、取消释放和失败回退原因；避免无效的逐行释义。

4.3 内容许可

文章保留中文维基百科来源、修订信息和 CC BY-SA 4.0 标识。图片许可依原文件页；内容改编保留来源和修改说明。代码公开评审不自动改变第三方内容许可，也不等于项目代码已选择开源许可证。

05 AI 技术选型理由与集成

方案	采用理由	代价与边界
DeepSeek 云 API	避免本地模型权重，兼容 HTTP 接口、支持流式	网络和费用依赖；生成有不确定性
豆包 embedding	中文语义与云端计算；现配置固定 1024 维	不同于生成模型密钥；索引版本必须一致
Chroma	轻量 REST 接入、持久化、可限制容器资源	内存随向量与索引增长，磁盘持久化不等于零内存
MySQL 原文库	同时满足内容、权限、来源与业务存储	查询与审核状态需保持一致

5.1 具体配置

生成配置由 LLM_BASE_URL、LLM_API_KEY、LLM_MODEL 控制；代码当前默认模型标识为 deepseek-flash，不宣称始终为官网最新型号。embedding 使用 doubao-embedding-vision-251215 的纯文本输入，固定 1024 维，维度与模型记入集合元数据。

5.2 为什么不自训练或本地部署

本项目价值在知识与教学流程集成。当前资源无法合理承担大模型本地推理与训练；使用云 API 使主机主要承载业务和检索。普通词条搜索采用 MySQL 标题检索，避免在同机同时运行 ES 的额外内存需求。

选型是现有约束下的工程权衡，不是模型能力排名或唯一最优结论。模型可用性、价格和区域以实际开通账户为准。

06 RAG 离线建库实现

6.1 数据流

公开中文条目筛选 → 章节内容前缀读取 → 800 字片段与 100 字重叠 → 云端 embedding → 向量归一化 → Chroma 写入。

每章最多处理前 12,000 字，以限制单次读取和费用。规划工具按同一规则统计，当前估计 5,000 篇、41,649 个有效章节、48,560 个片段；5 个章节触及截取上限，不把这些尾部称为已完整覆盖。

6.2 幂等与一致性

片段 ID 结合章节 ID、片段位置，以及标题、章节标题与内容的摘要。建库前查询已有 ID，相同内容不重复调用 embedding；中断后可以重新扫描并跳过已完成片段。处理数量包含复用项，新增数量才表示本轮新写入。

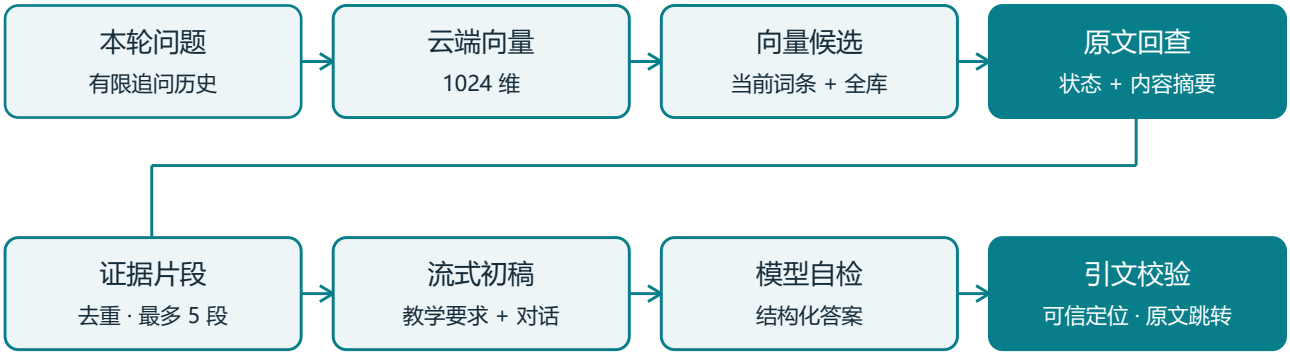
Chroma 仅保存向量和 article_id、section_id 等定位信息，正文仍从 MySQL 读取。集合校验模型、维度和切分格式，避免混写不同向量空间。当前不自动删除全部旧向量，因此内容更新后的过期项需要后续维护；在线回查会拒绝不匹配的旧内容。

6.3 容量与费用控制

48,560 × 1024 × 4 字节约为 189.7 MiB 原始向量，仅是下界，未包含图索引、运行时、缓存和查询开销。先用 -plan 无云调用估算，再 coverage 扩大词条覆盖，最后在记录预算和资源观测下扩正文。

建库使用小批请求与间隔，索引器 GOMEMLIMIT 辅助控制 Go 堆目标，但不是严格进程内存上限；Chroma 使用容器硬限制。后台运行保留日志，避免终端断开导致任务退出。

07 在线知识检索与证据选择



7.1 检索策略

问题附上当前标题进行 embedding；带“第二步、它、没听懂”等指代时，附最近两轮用户问题（各最多 400 字）及上一回答（最多 1600 字），不额外调用大模型改写。独立问题默认保持自身主题。

先查当前词条候选，再查全库候选；使用余弦距离阈值 0.65，过滤并去重，最多向模型提供 5 段证据。该阈值是当前策略，尚未基于标准标注集完成最优性评估。

7.2 原文回查与降级

检索后重新读取 MySQL 当前公开章节，排除隐藏、删除、未发布、待审或驳回内容，并重新验证片段摘要。过期向量不能绕过公开状态。证据不可用、超时、并发满或无相关结果时，退回当前词条有限片段并显示回退状态。

指代规则不是完整语义理解；省略过多或指向很早历史时可能检索不准。下一步应以固定问题集测量相关性，而不是盲目放宽阈值。

08 流式生成、模型自检与引用验证

8.1 双阶段生成

第一阶段输入本轮问题、有限历史、教学要求与检索证据，使用 SSE 逐段发送初稿。第二阶段再次调用模型，对事实、前提、推理与引用进行自检，输出结构化 summary、steps、citations 和 checks；最终替换初稿。

这种设计改善开始等待的感受，也使最终答案能够结构化显示；代价是一次回答有两轮生成调用，自检会增加完成时间。用户可停止生成，取消信号传递给后端与上游请求；停止后不能把未完成初稿标成核验成功。

8.2 服务器端引用检查

引用必须包含有效 S 编号以及在对应证据中精确出现的短句。来源文章 ID、slug 和章节 ID 由后端回填，不信任模型生成的定位信息。没有有效引文的知识性最终答案会被拒绝，界面显示未完成，不伪装成功。

8.3 明确的能力边界

原文精确匹配只证明引文存在；它不能证明每一句结论均得到支持，更不能代替数学形式化验证。第二轮仍是同类生成模型，可能重复错误；confidence 不是经校准的正确率，当前界面使用“模型自检完成”而非“数学证明通过”。

普通感谢、寒暄和结束对话无需硬套数学推导或编造引文。用户历史和词条文本都不应被当作系统指令或独立事实证据。

09 个性化教学与连续追问

9.1 表达偏好优先级

本轮明确要求的读者程度、语言难度、篇幅和解释方式，优先于下拉框默认值；历史回答的风格不覆盖本轮选择。优先级只影响讲法，不改变事实与引用规则。

小学生：从可观察情景出发，短句解释新术语；高中生：连接中学代数几何；本科生：补足关键定义与推理；专业学习者：关注前提、形式化定义、边界与条件。

生活类比说明对象对应和局限；直觉与严谨分开动机和结论；公式推导先解释符号；例题演示给小而完整的条件、过程与检查。不适合推导的简单问题不强行编造公式。

9.2 双阶段一致性

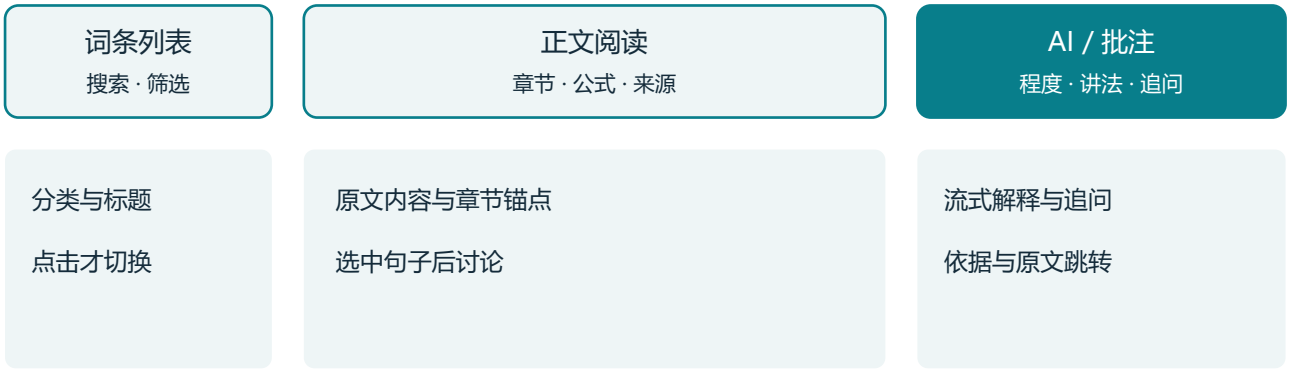
生成和自检共享表达要求；同步接口的自检也保留用户原问题。用户说“没听懂”时要求换情景、降术语密度，不只是把原句略缩短。引文可保留专业原句，讲解仍应符合读者程度。

9.3 现阶段结果与限制

用户提供的像素偏移截图出现了方格纸类比、分步骤说明和类比局限，说明模式能影响真实回答；摘要仍偏长，不能据单个例子断言教学效果显著。自动测试验证要求正确传递，不能验证模型每次均遵守。

对话历史最多保留近期 6 轮、总字符预算 32,000；刷新恢复和长期学习画像仍属于后续改进。追问检索使用规则补上下文，避免再增加一次模型请求的费用与延迟。

10 核心功能与交互实现



图：根据现有界面绘制的交互布局示意，不是运行截图。实际输出以演示视频和部署验收为准。

10.1 搜索与阅读分离

输入检索词和切换筛选不立即清空正文与 AI 会话；点击结果才打开条目。手机以列表、正文、AI 三个视图切换，减少桌面三栏挤压。公式和表格保留结构，HTML 与图片 URL 经过清洗。

10.2 讨论与反馈闭环

选中句子后创建批注，讨论锚定原文；审核后公开，支持评论和解释反馈。引用按钮可打开对应文章和章节，跨文章跳转按现有会话规则处理。

已有管理员可在账户管理授权或撤销他人，要求原因及二次确认；角色、旧会话失效与审计同一事务变更。禁止自我修改和提升封禁账户，目标需重新登录。首次管理员仍由运维工具建立。

本轮未配置语音时不再显示麦克风，避免入口暗示服务已可用。Enter 发送、Ctrl+Enter 换行，并处理中文输入法组合状态。键盘弹出和极长公式仍需持续真机验收。

11 安全、资源与费用控制

11.1 身份与内容边界

会话使用随机 Cookie，数据库保存其摘要；密码使用 bcrypt，管理员权限从服务端读取。写请求同源校验，注册必须邮箱验证。公开导出不含账户、密码哈希、批注、收藏、反馈或对话数据。

密钥只在后端，VITE_ 变量不能放凭据。输入 HTML、媒体 URL 和公式链接须清洗。RAG 的在线回查阻止过期隐藏内容从旧索引重新公开。

11.2 本轮 AI 准入保护

同步和流式端点共享限额：每账户同时一条，默认全局最多两条，每账户一分钟最多六次准入；配置分别为 AI_MAX_CONCURRENT 和 AI_REQUESTS_PER_MINUTE。拒绝发生在检索和模型调用之前，返回 429 / 503 与 Retry-After。

错误、取消和异常均释放并发占用；已准入但失败仍消耗窗口计数。记录过期回收并有总量上限。该方案只适用单 API 实例，进程重启会重置，不能充当充值余额或多实例分布式限额。

11.3 网络与部署

MySQL、Chroma 仅本机访问；正式对外服务应使用 TLS 与安全 Cookie。当前生产 HTTP 是已知部署限制，不能在文档中宣称传输已加密。Chroma 卷应备份并验证恢复，镜像摘要固定；重启策略避免宿主重启后服务忘记启动。

历史 PHP 安全通知经进程、目录与容器检查未发现对应运行服务；这不是全机安全审计结论，操作系统更新需独立维护。

12 测试设计与验证口径

测试层	覆盖行为	不代表什么
AI 协议模拟	流式分片、取消、自检、偏好要求传递	不等于真实模型质量
RAG	维度、归一化、幂等、过期 / 私有内容拒绝	不等于全题库检索准确率
业务权限	注册、会话、审核、账户隔离、数据 DTO	不等于全面渗透测试
AI 限额	同步流式共享、并发拒绝、恢复、异常释放	不等于大规模压测
前端	键盘、SSE、导航保留、媒体清洗、引用跳转	不等于全部真机兼容

12.1 可重复命令

go -C backend test ./...

go -C backend vet ./...

pnpm --dir frontend test

pnpm --dir frontend build

GitHub Actions 在 push / pull_request 运行上述检查和凭据模式扫描。真实 MySQL 与 Chroma 测试须配置隔离实例，默认跳过，不得将“跳过”记为真实集成通过。云模型请求使用本地模拟服务，避免测试账单。

12.2 后续评价方案

拟整理 30 个有标准证据的问题，覆盖定义、步骤、条件和追问；人工评估检索前 5 段相关性、回答有据性、读者难度遵循、首次输出与总完成时间。该评价尚未执行，因此本文不填写虚构命中率或延迟数值。

13 部署方案与资源实测

13.1 两条运行路线

本地评审：Go + SQLite 与 Vite，无密钥可查看阅读及明确标记的引用示例；配置邮件与云密钥后可测试真实账户和 AI。生产：原生 Go / Nginx，Docker MySQL 9.0.1、Chroma；Compose 为新的 MySQL 8.4 复现方案，不能接管或降级现有数据目录。

新 Compose 用命名卷；旧 E 盘 bind 安装使用兼容覆盖文件并先备份。原生 CHROMA_URL 指向 localhost，容器连接用 CHROMA_DOCKER_URL 的服务名。Go 不自动读取 .env，由启动包装器或进程环境加载。

13.2 可追溯的生产记录

指标	2026-10-17 建库完成后的截图值
向量集合	48,560 个片段
Chroma 内存	251.2 MiB / 384 MiB，约 65.42%
宿主 available	约 523 MiB
状态	running，OOMKilled=false

以上证明该次建库后规模能在当前限制下运行；不是完整生命周期峰值、并发检索峰值或 SLA。磁盘 IO 累计值不能当数据库文件大小。尚无正式并发容量报告。

13.3 发布与恢复

发布完整源码包，避免 plan.go / index.go 混用；构建成功后替换二进制并重启 Supervisor。前端编译发布 dist，保留回滚副本。索引与 .env 不随更新包覆盖；失败先看日志与状态，不靠清库解决。详细命令在 environment.md 和 review-release.md。

14 技术创新点与应用创新点

14.1 技术创新：项目集成层面的改进

1. 双存储证据链：Chroma 负责语义候选，MySQL 负责当前公开原文；检索后检查公开状态及内容摘要，使失效索引不能直接成为答案证据。

2. 三层引用约束：检索片段编号、模型自检、服务器精确引文匹配及可信元数据回填。把可回查性落实到章节，而不是仅在答案末尾列网页地址。

3. 低资源建库路径：云端向量化、1024 维表示、内容摘要幂等、容量规划与分阶段覆盖，避免本机模型占用，并用真实建库后截图约束容量表述。

4. 轻量追问检索：有限历史补足指代，与生成历史区分；不新增一轮模型改写请求，兼顾成本和语境。

14.2 应用创新：学习流程层面的改进

1. 阅读、讲解、引用核对和原句批注位于同一知识工作区，降低跨平台切换。

2. 学习程度与解释方式独立组合，允许用户本轮自然语言覆盖默认选择，使同一词条服务不同基础的读者。

3. 以来源章节为纽带连接 AI 答案和社区反馈，使错误能回到具体知识位置讨论。

4. 搜索不打断阅读，移动端分视图降低三栏界面的空间压力。

14.3 创新声明边界

以上是本项目的工程与应用组合特点，不主张发明 RAG、向量数据库、链式验证或获得算法层面的首创。没有训练专属数学模型，也没有形式化证明器；尚未有对照实验支持“显著提高成绩”之类结论。

15 总结、限制与展望

15.1 总结

项目实现了从公开数学词条到语义检索、分层解释、来源回查与社区讨论的可运行闭环。生产建库完成 48,560 段，在有限主机资源下形成了可观察的部署结果。仓库提供配置模板、依赖锁文件、测试入口与复现路径，支持评审独立查看代码。

15.2 当前限制

- 双阶段生成增加总等待，最终答案可能与流式初稿不同；应继续改善状态提示与重排体验。
- 规则识别追问无法完整解析所有指代；检索阈值与证据排序尚缺标准问题集校准。
- 模型自检并非独立事实裁判，存在相关错误；引文存在不等于结论正确。
- 超长章节尾部未全部建库；复杂模板和外链图片存在解析及可用性限制。
- 会话刷新恢复、长期画像与共享配额尚待完善；HTTP 部署与并发峰值验证仍是上线边界。

15.3 优先级路线

近期：部署本轮保护，验收不同程度与追问；建立 30 题人工标注集，分开记录检索、初稿、自检耗时。中期：优化查询相关性、对话恢复、移动端真机兼容，建立内容更新后的过期向量清理流程。后续：在具备明确需求和资源后引入重排序、混合检索或更完善的权限过滤。

语音输入与 Elasticsearch 在资源和 HTTPS 条件满足后再评估，不能为凑技术路线强行启用。每个新增组件应证明可衡量收益，而不是只增加架构图中的方框。

16 团队分工与参考资料

成员	项目职责
陈子扬	项目组长；需求分析、知识库结构、数据整理与规范化、统筹和文档
郑竣杰	架构、前后端、数据库、AI 集成、测试、部署和维护
陈伟	指导教师；副教授，应用数学方向，理论指导

团队信息依据用户提供的申报书整理。原材料未列独立团队品牌名称，使用“数学与算法交互式维基论坛项目组”。个人电话、学号不进入公开材料。

参考与复现入口

1. 项目仓库：https://github.com/moonriver05/- ，实现依据为 backend/internal/ai、rag、api 及 frontend/src。

2. DeepSeek 接口文档：https://api-docs.deepseek.com/ 。模型标识与权限应核对开通账户。

3. 火山方舟 embedding 接口：https://docs.volcengine.com/docs/ark/multimodal-vectorization-api?lang=zh 。本项目固定纯文本 1024 维方案。

4. Chroma 资源说明：https://cookbook.chromadb.dev/core/resources/ 。容量估算包含原始向量之外的开销。

5. 数据来源与许可：datasets/README.md、各条目 sourceUrl / revisionId / license；许可全文 https://creativecommons.org/licenses/by-sa/4.0/ 。

6. 需求与团队来源：用户提供的《一个基于大模型的数学与算法的交互式维基论坛》申报书；属于背景资料，不将计划描述当作已实现事实。

提交完整性

技术文档限制：PDF 不超过 30 页。视频要求：5-8 分钟、MP4、至少 1920×1080、普通话讲解，包含介绍、核心功能及 AI 亮点；公开平台发布后填写可访问链接。当前配套讲稿与分镜为录制素材，不冒充已发布视频。